

Caso prático: prevenendo o churn de SaaS



Plataforma completa de aprendizado
contínuo em programação.

#BoostingPeople

rocketseat.com.br

Todos os direitos reservados © Rocketseat S.A.



Cenário

Você é analista de dados em uma empresa SaaS que oferece planos mensais de assinatura. **A diretoria está preocupada com o aumento da taxa de cancelamento (churn)** e quer prever quais clientes estão mais propensos a sair e entender o porquê.

Objetivo

Prever o churn de clientes e gerar insights acionáveis sobre os principais fatores que influenciam essa saída.



Contexto do Negócio

A empresa oferece três tipos de planos: **Basic, Standard e Premium**. Os clientes acessam a plataforma via navegador e interagem com funcionalidades, suporte e e-mails. A meta da área de dados é prever o risco de churn (cancelamento) com base no comportamento e no perfil do cliente.



Variáveis disponíveis

- `id_cliente`, `codigo_cliente`, `constante`: identificadores & coluna constante (irrelevantes para modelagem).
- `idade` (18–69 anos)
- `tempo_de_contrato_meses` (1–59 meses)
- `frequencia_uso_mensal` (0–29 acessos/mês)
- `ultimo_login_dias` (0–59 dias desde último acesso)
- `suporte_chamados_abertos` (número de chamados — Poisson média ≈ 2)
- `uso_funcionalidades_premium` (proporção $[0,1]$ de uso de recursos pagos)
- `interacao_emails_marketing` (0–9 interações)
- `plano` (Basic | Standard | Premium)
- `pagamento_em_dia` (1 = sim / 0 = não)
- `avaliacao_satisfacao` (nota 1.0–5.0, simétrica em torno de 3.5)
- `regiao` (Sul | Sudeste | Centro-Oeste | Norte | Nordeste)
- `tempo_total_login_horas` (média ≈ 50 h/mês)
- `navegador_usado` (Chrome | Firefox | Safari | Edge)
- `hora_ultimo_acesso` (0–23)
- `churn` (0 = cliente ativo / 1 = cliente cancelou)



EDA inicial

1. Cerca de 80 % dos clientes permaneceram ativos (churn = 0) e 20 % cancelaram (churn = 1).
2. Há um leve desequilíbrio de classes (4:1). É importante lembrar disso ao criar modelos (ex.: balancear amostras ou usar métricas além de acurácia).
3. As variáveis mostram amplitude razoável (nenhum viés extremo), mas veremos que “pagamento_em_dia” pode ser importante para churn. A distribuição exponencial de “tempo_total_login_horas” indica que há muitos usuários de “baixa atividade” e poucos de “alta atividade”.



EDA Detalhada

1. Nenhum missing → parte do pré-processamento não exige imputação
2. Principais preditores univariados de churn:
 - a. Não pagamento em dia (inadimplência)
 - b. Maior número de dias sem login
 - c. Baixa frequência de uso mensal
 - d. Baixo uso de funcionalidades premium
 - e. Avaliação de satisfação baixa
 - f. Plano mais simples (Basic) churning mais
3. Variáveis removíveis: `id_cliente` e constante.
4. Multicolinearidade leve entre `"tempo_total_login_horas"` e `"frequencia_uso_mensal"` → avaliar manter apenas a mais forte.
5. Categorias com pouco impacto (ex.: navegador) podem ser combinadas ou excluídas se não melhorarem o modelo.

Próximos passos

1. Pré-processamento: Remover colunas irrelevantes, codificar (One-Hot / LabelEncoder), verificar correlação.
2. Feature Engineering: criar uso_total, suporte_freq, bin_..., etc.
3. Feature Selection: usar VIF e SelectKBest / RFE para escolher as variáveis mais relevantes.
4. Treinamento comparativo:
 - a. Regressão Logística
 - b. Random Forest
 - c. XGBoost
 - d. SVM (ou outro alg. de sua escolha)
5. Avaliar com validação cruzada (AUC, F1, Precision/Recall).
6. XAI: aplicar SHAP e/ou LIME para explicar as previsões de churn e extrair insights acionáveis (por ex., “inadimplência + 30 dias sem login → 90 % de chance de churn”).

Conclusão

- Vamos para a prática?